Resumen de paper: A systematic review of dengue outbreak prediction models: Current scenario and future directions

1. Referencia

Leung, X. Y., Islam, R. M., Adhami, M., Ilic, D., McDonald, L., Palawaththa, S., Diug, B., Munshi, S. U., & Karim, M. N. (2023). A systematic review of dengue outbreak prediction models: Current scenario and future directions. *PLOS Neglected Tropical Diseases, 17*(2), e0010631. https://doi.org/10.1371/journal.pntd.0010631

Revisión sistemática revisada por pares, publicada el 13 de febrero de 2023 en acceso abierto (CC BY) y registrada en PROSPERO (CRD42018102100). Es una revisión de la literatura y no un estudio con datos propios, por lo que no usa el dataset de nuestro proyecto.

2. Problema y objetivo

Existen decenas de modelos para anticipar casos o brotes de dengue, pero se construyen con predictores muy distintos, se validan de maneras desiguales y no hay acuerdo sobre cuál funciona mejor. Los autores buscan describir cómo se desarrollan hoy estos modelos (datos, variables, técnicas y validación) y señalar qué prácticas deberían corregirse.

3. Metodología

Buscaron en MEDLINE, Embase, Scopus y Web of Science hasta octubre de 2022, además de Google Scholar y las referencias de los artículos incluidos, guiándose por la lista CHARMS (específica para modelos de predicción) y PRISMA. Incluyeron solo modelos que predicen casos o brotes de dengue; excluyeron los modelos del mosquito, los análisis solo de correlación, los modelos de transmisión tipo SIR y los modelos solo espaciales o solo temporales. Dos revisores evaluaron cada artículo de forma independiente. De 6,553 registros encontrados, 64 estudios cumplieron los criterios y aportaron **99 modelos**, entre ellos uno de Perú (Buczak et al., 2018, PLoS One).

4. Hallazgos principales

- **Datos:** los casos vienen casi siempre de vigilancia o notificación (90.7 %), y el clima de reportes de agencias gubernamentales (94.7 %); solo 22.1 % usó estaciones meteorológicas. La agregación fue mensual (46.9 %), semanal (29.3 %) o diaria (23.2 %). Solo 17.2 % de los modelos trató los datos faltantes y 52.5 % no lo reportó.
- **Qué se predice:** el número de casos en 80.8 % de los modelos y la ocurrencia de un brote sobre un umbral en 19.2 %.
- **Predictores:** todos los modelos usan clima, sobre todo temperatura (95.2 %), lluvia (81.0 %) y humedad (77.4 %); 70.7 % usa solo clima. Las variables de El Niño (ENSO, SOI, ONI) y del ambiente aparecen en 18.2 %, las del vector en 8.1 % y las demográficas en 8.1 %. Ningún modelo combina las cuatro categorías.
- **Rezagos:** 59.6 % de los modelos ajustó el rezago temporal entre las variables y los casos.
- **Validación:** 75.8 % validó solo internamente, 5.2 % también externamente y 20.2 % no validó. La técnica más común fue la validación cruzada (40.5 %), seguida de dividir la muestra (20.3 %); ninguno usó bootstrapping. Las métricas más reportadas fueron RMSE (11.1 %), MSE (7.3 %), MAE (7.1 %) y MAPE (5.1 %).

Estadísticos (60 modelos, 60.6 %)	Machine learning (39 modelos, 39.4 %)
Series de tiempo / autorregresivos 26.7 %; regresión lineal 18.3 %; Poisson 18.3 %; GAM 16.7 %; no lineal 8.3 %	Redes neuronales 23.1 %; random forest 15.4 %; boosting 12.8 %; SVM, ensambles y LSTM 10.3 % cada uno

Los porcentajes de técnicas son dentro de cada grupo, no sobre los 99 modelos.

5. Discusión y conclusiones de los autores

- Identifican tres fallas: se usan datos secundarios (reportes) en vez de datos primarios en tiempo real, casi no se incluyen variables no climáticas y el reporte de métodos, validación y desempeño es insuficiente. La vigilancia pasiva puede subestimar casos y retrasar su notificación.
- Consideran indispensable ajustar rezagos al usar clima, porque el efecto del clima pasa por el desarrollo del mosquito, la amplificación del virus y el periodo de incubación.
- Valoran el giro hacia técnicas más robustas: las series de tiempo captan la fuerte autocorrelación del dengue, y el machine learning ya está en cerca de 40 % de los modelos (Batista et al. reportan menor error que los modelos estadísticos). Mencionan random forest, redes neuronales, gradient boosting y SVM como técnicas con aportes en pronóstico de malaria y COVID-19, y sugieren explorar modelos mecanicistas.
- Advierten que los modelos rinden menos con datos nuevos (*validity shrinkage*), que dividir la muestra puede dar estimaciones pesimistas y variables, y que el bootstrapping es el método interno preferido.
- Limitaciones propias: no calificaron la calidad de los modelos, la calibración estaba mal definida en varios estudios y no pudieron comparar el desempeño entre técnicas por falta de datos comparables, pues casi todo viene de validación interna.

6. Aplicación a nuestro proyecto

Lo que muestra el paper	Qué haremos
El rezago entre clima y casos es indispensable	Usar el clima con rezagos de 2, 4, 6 y 8 semanas, y los rezagos del propio log de casos, para predecir a 4 semanas. En nuestro EDA la correlación máxima apareció entre 7 y 10 semanas (solo dos temporadas).
Series de tiempo y ML son las técnicas en crecimiento	Baseline con la media y un modelo autorregresivo; luego regresión lineal con Ridge, árbol de regresión y KNN (del curso), y random forest y un MLP (de la literatura).
Casi todos usan solo clima	Añadir el ICEN (El Niño costero) y la semana del año como seno y coseno.
Datos secundarios, sin tiempo real	Declarar como limitación que usamos vigilancia del MINSA y clima de reanálisis (NASA POWER, celdas de unos 55 km).
Validación y faltantes mal reportados	Reportar MAE, RMSE y R^2 en train, validación y test, comparar validación cruzada contra test y documentar el tratamiento de faltantes.